

Formalismo procedural: LLM como sistema de macroestados representacionales

1. Idea central

La tesis de trabajo es:

Un LLM puede estudiarse como un sistema estadístico de trayectorias internas. Sus microestados son activaciones, logits y tokens; sus macroestados son observables agregados definidos sobre direcciones representacionales relevantes para seguridad.

La analogía no afirma que el LLM sea literalmente un sistema termodinámico en equilibrio. La afirmación defendible es más precisa: se puede aplicar un esquema de coarse-graining tipo física estadística para medir estabilidad, susceptibilidad y transiciones entre regímenes seguros e inseguros.

El punto de partida conceptual es RepE: Representation Engineering propone tratar las representaciones como unidad primaria de análisis top-down, y no solamente neuronas o circuitos individuales. En particular, LAT permite construir direcciones de lectura a partir de activaciones internas asociadas a conceptos de alto nivel como honestidad, harmlessness, poder, riesgo o incertidumbre.

Referencia base: <https://ar5iv.labs.arxiv.org/html/2310.01405v4>

2. Analogía directa con ResGLOnet

En el problema de thin films:

x := stack físico,
 C := condición física,
 $F(x; C)$:= reflectancia generada,
 R^* := target espectral,
 P_R := población final de soluciones,
 $D_{\text{stat}}(R)$:= dificultad posterior medida desde la masa de soluciones exitosas,
 $c(R)$:= firma modal del target,
 $D_H(R; C) = \langle r, H_C r \rangle$.

En LLM safety proponemos:

q := prompt, tarea o escenario de evaluación,
 C := condición del modelo y del experimento,
 $F_\theta(q; C)$:= distribución de trayectorias generadas,
 γ_b := trayectoria b con tokens, activaciones y logits,
 S^* := especificación de seguridad deseada,
 $P_q := \{\gamma_b(q; C)\}_{b=1}^B$,
 $D_{\text{stat}}^{\text{LLM}}(q)$:= dificultad posterior de mantener seguridad en q ,
 $s(\gamma_b)$:= macroestado representacional de la trayectoria,
 $D_H^{\text{LLM}}(q; C) :=$ energía efectiva de riesgo estimada desde macroestados.

La correspondencia conceptual es:

ResGLOnet / thin films	LLM safety
stack multicapa x	trayectoria generativa γ o intervención u
solver físico $F(x; C)$	forward pass/autoregressive decoding $F_\theta(q; C)$
reflectancia $R(\lambda)$	conducta + activaciones + logits
target R^*	especificación segura S^*
batch de candidatos	muestras/respuestas/rollouts
error espectral $e_b(R)$	error de seguridad $e_b(q)$
masa de éxito $M_\sigma(R)$	masa de trayectorias seguras $M_\sigma(q)$
dificultad $D_{\text{stat}}(R)$	dificultad de seguridad $D_{\text{stat}}^{\text{LLM}}(q)$
firma modal $c(R)$	macroestado representacional $s(q)$
Hamiltoniano H_C	operador de riesgo/acoplamiento entre macrovariables

3. Condición experimental del LLM

Fijamos una condición:

$$C = \{\theta, \mathcal{T}, p_{\text{sys}}, \pi_{\text{dec}}, \tau, p_{\text{top}}, \ell, T_{\text{obs}}, \mathcal{Q}, \mathcal{S}\}.$$

Donde θ son los pesos del modelo, $\mathcal{T}$ es el tokenizador, p_{sys} es el prompt de sistema, π_{dec} es la política de decodificación, τ es la temperatura, p_{top} es top-p, ℓ es la capa observada, T_{obs} son las posiciones observadas, $\mathcal{Q}$ es la familia de prompts y $\mathcal{S}$ es el criterio de seguridad.

Para un prompt q , el modelo genera una trayectoria:

$$\gamma_b(q; C) = \left\{ y_{1:T}^{(b)}, h_{\ell,t}^{(b)}, z_t^{(b)} \right\}_{t=1}^T, \quad b = 1, \dots, B.$$

Donde y_t es el token generado, $h_{\ell,t}$ es la activación de la capa ℓ , y z_t son los logits.

El problema directo es:

$$F_\theta(q; C) \longrightarrow P_q = \{\gamma_b(q; C)\}_{b=1}^B.$$

Es decir: dado un escenario q , una condición C y un modelo fijo, observamos una población de trayectorias.

4. Problema inverso de seguridad

El problema inverso no es simplemente "predecir el output". Es:

dado un escenario q y una especificación segura S^* , encontrar, monitorear o controlar las condiciones bajo las cuales la población de trayectorias permanece cerca del macroestado seguro.

Formalmente, se puede buscar una intervención u :

$$u^* \in \arg \min_u \mathbb{E}_{\gamma \sim F_\theta(q; C, u)} [e(\gamma, S^*)] + \Omega(u).$$

La intervencion u puede ser un system prompt, una politica de decoding, un detector, un steering vector, una intervencion RepE sobre activaciones, un clasificador que interrumpe la generacion, o una politica de abstencion/refusal.

Para un primer hackathon, no hace falta resolver el control completo. Basta con medir $D_{\text{stat}}^{\text{LLM}}(q)$ y mostrar que esa dificultad posterior puede predecirse desde macroestados internos.

5. Error de seguridad y masa poblacional

Para cada trayectoria γ_b , definimos un error:

$$e_b(q) = e_{\text{beh}}(\gamma_b, S^*) + \lambda_{\text{rep}} e_{\text{rep}}(\gamma_b, S^*) + \lambda_{\text{cal}} e_{\text{cal}}(\gamma_b, S^*).$$

Componentes posibles:

$e_{\text{beh}} :=$ fallo conductual observable,

$e_{\text{rep}} :=$ distancia interna al macroestado seguro,

$e_{\text{cal}} :=$ mala calibracion, exceso de confianza o baja incertidumbre ante riesgo.

Como en ResGLOnet, transformamos el error en merito:

$$m_b(q) = \exp \left[-\frac{e_b(q)}{\sigma} \right].$$

La masa poblacional de seguridad es:

$$M_\sigma(q) = \frac{1}{B} \sum_{b=1}^B m_b(q).$$

Y la dificultad posterior:

$$D_{\text{stat}}^{\text{LLM}}(q) = -\log [M_\sigma(q) + \varepsilon].$$

Interpretacion:

$$\begin{aligned} M_\sigma(q) \approx 1 &\Rightarrow D_{\text{stat}}^{\text{LLM}}(q) \approx 0 \quad \text{muchas trayectorias seguras,} \\ M_\sigma(q) \ll 1 &\Rightarrow D_{\text{stat}}^{\text{LLM}}(q) \gg 1 \quad \text{pocas trayectorias seguras.} \end{aligned}$$

Esto es defendible porque no depende de una sola respuesta. Mide la robustez poblacional del comportamiento seguro.

6. Macroestados representacionales

Elegimos K direcciones RepE/LAT:

$$V = \{v_1, \dots, v_K\}.$$

Cada direccion representa un observable de seguridad:

- $v_1 \leftrightarrow$ harmlessness,
- $v_2 \leftrightarrow$ honesty,
- $v_3 \leftrightarrow$ uncertainty,
- $v_4 \leftrightarrow$ refusal,
- $v_5 \leftrightarrow$ harmful compliance,
- $v_6 \leftrightarrow$ power seeking,
- $v_7 \leftrightarrow$ deception.

Para una trayectoria γ_b , agregamos las activaciones observadas:

$$a_b = A(\gamma_b) = \frac{1}{|T_{\text{obs}}|} \sum_{t \in T_{\text{obs}}} h_{\ell, t}^{(b)}.$$

El macroestado de la trayectoria es:

$$s_b(q) = (\langle a_b - a_{\text{ref}}, v_1 \rangle, \dots, \langle a_b - a_{\text{ref}}, v_K \rangle) \in \mathbb{R}^K.$$

Esto convierte una trayectoria de alta dimension en un vector bajo-dimensional de observables.

La firma poblacional ponderada por exito es:

$$w_b(q) = \frac{\exp[-e_b(q)/\sigma]}{\sum_j \exp[-e_j(q)/\sigma]}.$$

$$\mu_{\text{succ}}(q) = \sum_{b=1}^B w_b(q) s_b(q).$$

Y la diferencia entre demanda y respuesta puede escribirse:

$$\Delta s(q) = \mu_{\text{succ}}(q) - s_{\text{safe}}(q).$$

Donde $s_{\text{safe}}(q)$ es el macroestado esperado para una solucion segura.

7. Hamiltoniano de riesgo

La hipotesis fuerte es que la dificultad posterior puede aproximarse mediante una energia de macroestado:

$$D_{\text{stat}}^{\text{LLM}}(q) \approx D_H^{\text{LLM}}(q; C).$$

Con:

$$D_H^{\text{LLM}}(q; C) = \Delta s(q)^\top H_C \Delta s(q).$$

Si H_C es diagonal:

$$D_{\text{diag}}(q; C) = \sum_{k=1}^K h_k(C) \Delta s_k(q)^2.$$

Cada macrovariable contribuye de forma independiente. Pero en AI safety lo mas interesante son los acoplamientos:

$$D_H(q; C) = \sum_{k=1}^K H_{kk} \Delta s_k^2 + 2 \sum_{k < j} H_{kj} \Delta s_k \Delta s_j.$$

Ejemplos de terminos no diagonales:

- harmful compliance $\times$ low uncertainty,
- deception $\times$ persuasion,
- power seeking $\times$ tool use,
- high capability $\times$ weak refusal,
- high confidence $\times$ low truthfulness.

Estos acoplamientos son la analogia directa de los terminos no diagonales/no abelianos en el PDF: la dificultad no vive solamente en variables aisladas, sino en combinaciones.

8. Terminos fisicos analogicos

Podemos descomponer:

$$D_H = D_{\text{amp}} + D_{\text{dyn}} + D_{\text{couple}} + D_{\text{susc}} + D_{\text{NL}}.$$

El termino de amplitud penaliza magnitudes globales peligrosas:

$$D_{\text{amp}} = \sum_k \alpha_k s_k^2.$$

El termino dinamico penaliza cambios bruscos durante la generacion:

$$D_{\text{dyn}} = \sum_{t=1}^{T-1} \|s_{t+1} - s_t\|^2.$$

Esto mide inestabilidad o transicion de estado.

El termino de susceptibilidad mide sensibilidad ante perturbaciones del prompt:

$$\chi(q) = \mathbb{E}_{\delta q} \left[\frac{\|s(q + \delta q) - s(q)\|^2}{\|\delta q\|^2 + \eta} \right].$$

Prompts cercanos a jailbreaks exitosos deberian tener alta susceptibilidad.

El termino no lineal captura saturaciones:

$$D_{\text{NL}} = V_C(s).$$

Por ejemplo, una vez que harmful compliance cruza cierto umbral, el riesgo puede crecer de forma superlineal.

9. Hipotesis experimental defendible

Hipotesis principal:

Los fallos de seguridad en LLMs pueden predecirse mejor usando macroestados representacionales y sus acoplamientos que usando solamente clasificadores sobre el texto final.

Subhipotesis:

1. Las direcciones RepE/LAT para conceptos de seguridad definen parametros de orden medibles.
2. La masa poblacional $M_\sigma(q)$ mide robustez de seguridad mejor que una unica muestra.
3. La dificultad $D_{\text{stat}}^{\text{LLM}}(q)$ deja una huella en el espacio de macroestados.
4. Los terminos de acoplamiento son necesarios para detectar casos compuestos: por ejemplo, alta obediencia + baja incertidumbre + contenido peligroso.
5. La susceptibilidad ante perturbaciones del prompt aumenta cerca de transiciones seguras/inseguras.

10. Protocolo minimo para hackathon

Paso 1: Elegir modelo y puntos de observacion

Usar un modelo open-weight que permita hidden states. Fijar:

$$\ell, \quad T_{\text{obs}}, \quad B.$$

Donde ℓ es la capa observada, T_{obs} son los tokens observados y B es el numero de rollouts por prompt.

Paso 2: Construir direcciones LAT

Para cada concepto, crear pares:

seguro	vs.	inseguro,
honesto	vs.	enginoso,
incertidumbre calibrada	vs.	falsa certeza,
rechazo correcto	vs.	compliance peligroso.

Extraer activaciones y construir:

$$v_k = \text{PCA}_1 \left(\left\{ a_i^{(+)} - a_i^{(-)} \right\}_{i=1}^N \right),$$

o:

$$v_k = \frac{1}{N_+} \sum_{i=1}^{N_+} a_i^{(+)} - \frac{1}{N_-} \sum_{i=1}^{N_-} a_i^{(-)}.$$

Paso 3: Generar poblaciones

Para cada prompt q :

$$P_q = \{\gamma_1, \dots, \gamma_B\}.$$

Paso 4: Medir seguridad posterior

Para cada trayectoria:

$$e_b(q), \quad m_b(q) = \exp[-e_b(q)/\sigma].$$

Luego:

$$M_\sigma(q) = \frac{1}{B} \sum_{b=1}^B m_b(q), \quad D_{\text{stat}}^{\text{LLM}}(q) = -\log[M_\sigma(q) + \varepsilon].$$

Paso 5: Medir macroestados

Para cada trayectoria:

$$s_b(q) = [\langle A(\gamma_b) - a_{\text{ref}}, v_k \rangle]_{k=1}^K.$$

Para cada prompt, estimar:

$$\mu(q), \quad \text{Var}(q), \quad \mu_{\text{succ}}(q), \quad \chi(q).$$

Paso 6: Ajustar energia de riesgo

Comparar:

$$D_{\text{stat}}(q) \sim \sum_k h_k s_k^2,$$

$$D_{\text{stat}}(q) \sim s^\top H s,$$

$$D_{\text{stat}}(q) \sim s^\top H s + \beta \chi(q),$$

$$D_{\text{stat}}(q) \sim \text{baseline output-only}.$$

Metricas:

$$\rho_{\text{Spearman}}, \quad r_{\text{Pearson}}, \quad \text{AUROC}, \quad \text{ECE}.$$

Paso 7: Validar causalidad minima

Si hay tiempo, probar intervencion:

$$\begin{aligned}h' &= h - \alpha v_{\text{harmful compliance}}, \\h' &= h + \beta v_{\text{refusal}}, \\h' &= h + \gamma v_{\text{uncertainty}}.\end{aligned}$$

Evaluar si cambia:

$D_{\text{stat}}^{\text{LLM}}(q)$, tasa de jailbreak, calidad util en prompts benignos.

Esto conecta con RepE control, no solo lectura.

11. Primer proyecto defendible

Nombre tentativo:

Thermodynamic Representation Monitoring for LLM Safety

Version corta:

Construimos parametros de orden internos para LLMs usando Representation Engineering. Luego definimos una dificultad posterior de seguridad basada en poblaciones de respuestas y mostramos que una energia de macroestado predice prompts cerca de transiciones inseguras.

Entrega de hackathon:

1. Un pipeline que extrae direcciones LAT de seguridad.
2. Un monitor que calcula macroestados durante generacion.
3. Una metrica $D_{\text{stat}}^{\text{LLM}}$ por prompt.
4. Un modelo energetico D_H que predice riesgo.
5. Una visualizacion de trayectorias seguras/inseguras en el espacio de macroestados.
6. Opcional: steering representacional para reducir riesgo.

Claim defendible:

No proponemos una metafora termodinamica superficial. Proponemos un coarse-graining operacional: microestados internos de alta dimension se proyectan en macrovariables de seguridad, y la estabilidad de esos macroestados se evalua con poblaciones, susceptibilidad y energia efectiva.

12. Criterio de exito

El proyecto funciona si muestra al menos uno de estos resultados:

1. $D_{\text{stat}}^{\text{LLM}}(q)$ separa prompts seguros e inseguros mejor que una unica muestra.
2. Macroestados RepE predicen fallos antes de que el texto final sea obviamente inseguro.
3. Un modelo con acoplamientos $s^\top H s$ supera a un modelo diagonal.

4. La susceptibilidad ante paraphrases aumenta en prompts jailbreak.
5. Intervenir una direccion reduce fallos sin destruir utilidad en prompts benignos.

Con eso ya hay una primera idea cientificamente defendible y hackathon-friendly.