

Contexto matematico del problema inverso: de ResGLOnet a la lectura modal de la dificultad

Resumen parcial – ResGLOnet / thin films

Estructura fotonica y problema directo

Una estructura fotonica unidimensional se modela como un sistema multicapa formado por L peliculas delgadas. Cada capa ℓ queda caracterizada por un espesor e_ℓ y un indice de refraccion $n_\ell(\lambda)$. El diseno del stack se resume como

$$x = (e, n) = (e_1, \dots, e_L, n_1, \dots, n_L).$$

Las cantidades que no se optimizan se agrupan en una condicion fisica

$$C = \{n_{\text{top}}, n_{\text{sub}}, \theta, \text{pol}, \Lambda, L, e_{\text{min}}, e_{\text{max}}, \mathcal{M}\},$$

donde Λ es el dominio espectral discretizado y $\mathcal{M}$ la biblioteca o rango de materiales permitidos.

El problema directo consiste en calcular la reflectancia generada por un stack:

$$F(x; C) = R(\lambda; x, C).$$

En peliculas delgadas, F se obtiene mediante el metodo de matriz de transferencia. Siguiendo la notacion de la tesis de Agustina, en cada capa se escribe el campo como superposicion de ondas propagantes y antipropagantes,

$$f_j(x, y) = (A_j e^{-i\beta_j y} + B_j e^{i\beta_j y}) e^{i\alpha_j x}.$$

En la interfaz y_j , la continuidad del campo y de su derivada normal ponderada lleva a

$$M_j(y_j) \begin{pmatrix} A_j \\ B_j \end{pmatrix} = M_{j+1}(y_j) \begin{pmatrix} A_{j+1} \\ B_{j+1} \end{pmatrix},$$

con

$$M_j(y_j) = \begin{pmatrix} e^{-i\beta_j y_j} & e^{i\beta_j y_j} \\ -\frac{\beta_j}{\sigma_j} e^{-i\beta_j y_j} & \frac{\beta_j}{\sigma_j} e^{i\beta_j y_j} \end{pmatrix}.$$

La polarizacion queda incorporada en

$$\sigma_j = \begin{cases} \epsilon_j, & \text{TE,} \\ \mu_j, & \text{TM.} \end{cases}$$

Al multiplicar todas las matrices de interfaz se obtiene una matriz de transferencia total M que relaciona las amplitudes en superestrato y sustrato:

$$\begin{pmatrix} A_s \\ B_s \end{pmatrix} = M \begin{pmatrix} A_{\text{super}} \\ B_{\text{super}} \end{pmatrix}.$$

Como la iluminacion se impone desde el superestrato, se toma $B_s = 0$. La reflectancia queda definida como el cociente cuadratico entre amplitud reflejada e incidente:

$$R(\lambda; x, C) = \left| \frac{B_{\text{super}}}{A_{\text{super}}} \right|^2.$$

Esta ecuacion es el nucleo del problema directo: dado un stack x , el solver devuelve R . El diseno inverso pregunta por la operacion opuesta.

Formalismo del problema inverso

El problema inverso fija un objetivo R^* y busca un stack que lo reproduzca. En el formalismo del trabajo previo, para una estructura fonicamente admisible $x = (e, n)$, el error cuadratico se escribia como una comparacion entre la reflectancia generada y el target impuesto:

$$\text{Err}^2(e, n) = \frac{1}{N_\lambda N_\theta N_{\text{pol}}} \sum_{\lambda, \theta, \text{pol}} [R(e, n, \theta, \text{pol}, \lambda) - R^*(\theta, \text{pol}, \lambda)]^2.$$

Esta expresion explicita que el target no es solamente una curva en λ : puede depender tambien de angulo y polarizacion. Por eso el problema completo esta condicionado por C , no solo por R^* .

En forma compacta, el espacio de disenos permitido es

$$X_C = \{x = (e, n) : e_\ell \in [e_{\text{min}}, e_{\text{max}}], n_\ell \in \mathcal{M}, \ell = 1, \dots, L\}.$$

El problema inverso ideal seria

$$x^* \in \arg \min_{x \in X_C} \|F(x; C) - R^*\|^2.$$

Pero F es no lineal, altamente oscilatorio y depende de productos matriciales. Ademas, si los materiales son categoricos, X_C combina variables continuas y discretas. Esta es la razon por la que ResGLOnet resulta util: convierte la busqueda en una optimizacion generativa diferenciable guiada por el solver.

Optimizacion poblacional con ResGLOnet

ResGLOnet no optimiza un unico stack aislado. La red generativa toma variables latentes y produce un batch de estructuras candidatas

$$x^{(b)} = (e^{(b)}, n^{(b)}), \quad b = 1, \dots, B.$$

Cada candidato se evalua con el solver de matriz de transferencia y recibe un error $\text{Err}^2(e^{(b)}, n^{(b)})$. La funcion de perdida usada en el trabajo previo tiene la forma GLOnet:

$$\mathcal{L} = - \sum_{b=1}^B \exp \left[- \frac{\text{Err}^2(e^{(b)}, n^{(b)})}{\sigma} \right].$$

El parametro σ regula cuan selectiva es la poblacion: si σ es grande, muchos candidatos contribuyen al gradiente; si es chico, la perdida se concentra en los mejores candidatos. Esta formulacion permite que la red aprenda una distribucion de soluciones, no solamente un punto.

La figura 1 muestra por que la lectura poblacional es natural. No hay una unica curva azul, sino muchas respuestas generadas por la red. Algunas se aproximan muy bien al cristal




Figure 1: Ejemplo representativo del trabajo previo: ResGLOnet reproduce el PBG de un cristal fotonico de referencia de 12 capas. La nube azul muestra soluciones generadas por la red y la curva negra la referencia CF N12. El ajuste en la zona de interes alcanza $\text{Err}^2 < 10^{-5}$.

fotonico de referencia, mientras otras conservan diferencias fuera de la region principal. Por tanto, incluso cuando existe un buen mejor candidato, la poblacion contiene informacion sobre la estabilidad, abundancia y accesibilidad de la solucion.

Dificultad poblacional posterior

Se introduce primero un modelo cuantitativo de dificultad posterior. Su punto de partida no es una propiedad teorica del target, sino el resultado de un entrenamiento completo. Por eso la notacion debe separar tres objetos: R , el target de reflectancia que se desea imponer; $F(\cdot; C)$, el solver fisico de matriz de transferencia; y G_ω , el generador ResGLOnet con pesos entrenables ω . Para un target R y condiciones C , se entrena G_ω minimizando la perdida poblacional. Al final del entrenamiento se fijan los pesos ω_T . Luego se muestrea una poblacion final de B variables latentes z_b , y cada una produce un stack

$$x_b = G_{\omega_T}(z_b; R, C), \quad b = 1, \dots, B.$$

Cada stack se pasa por el solver:

$$R_b(\lambda) = F(x_b; C).$$

Asi, para un unico target R , el entrenamiento no devuelve solamente un mejor diseno, sino una poblacion final

$$\mathcal{P}_R = \{(x_b, R_b)\}_{b=1}^B.$$

La dificultad que se busca medir es una propiedad de esa poblacion final respecto del target R .

Para cada candidato se define el error cuadratico discreto

$$e_b(R) = \frac{1}{N_C} \sum_{q \in C_{\text{obs}}} [R_b(q) - R(q)]^2.$$

Aqui q representa una condicion observada, por ejemplo

$$q = (\lambda, \theta, \text{pol}),$$

C_{obs} es el conjunto de puntos espectrales, angulares y de polarizacion usados para comparar, y $N_C = |C_{\text{obs}}|$. En el

caso mas simple, $q = \lambda$ y el promedio es solamente sobre longitudes de onda.

El error e_b se transforma en un merito suave:

$$m_b(R) = \exp \left[-\frac{e_b(R)}{\sigma} \right].$$

El hiperparametro σ fija la escala de tolerancia: si $e_b \ll \sigma$, el candidato aporta mucho; si $e_b \gg \sigma$, su aporte es casi nulo. Con esto se define la masa poblacional de exito

$$M_\sigma(R) = \frac{1}{B} \sum_{b=1}^B m_b(R).$$

Esta magnitud resume cuanta parte de la poblacion final cae cerca del target. No es lo mismo que el mejor error

$$e_{\min}(R) = \min_b e_b(R),$$

porque $e_{\min}$ solo detecta un candidato afortunado. M_σ , en cambio, mide si la region de soluciones fue encontrada de manera robusta por la poblacion.

La dificultad estadistica posterior queda definida como

$$D_{\text{stat}}(R) = -\log [M_\sigma(R) + \epsilon].$$

El pequeno $\epsilon > 0$ evita la divergencia numerica si ningun candidato obtiene merito apreciable. Esta definicion tiene la interpretacion esperada:

$$\begin{aligned} M_\sigma(R) \approx 1 &\Rightarrow D_{\text{stat}}(R) \approx 0, \\ M_\sigma(R) \ll 1 &\Rightarrow D_{\text{stat}}(R) \gg 1. \end{aligned}$$

Por tanto, D_{stat} es una medida a posteriori de la dificultad de un target cualquiera R bajo las condiciones C y la dinamica de entrenamiento elegida. Se calcula despues de entrenar, observando la poblacion final.

Una lectura equivalente, usada como diagnostico, es la probabilidad dura de exito a umbral ϵ :

$$p_\epsilon(R) = \frac{1}{B} \#\{b : e_b(R) < \epsilon\}.$$

Mientras p_ϵ depende de elegir un corte, M_σ suaviza esa decision y permite definir D_{stat} sin fijar un unico umbral rigido. Esta fue la razon de usar D_{stat} como etiqueta experimental: no dice todavia por que un target es dificil, pero mide de forma estable si la poblacion final encontro una region amplia de soluciones.

Uso posterior de D_{stat}

El rol de D_{stat} dentro del proyecto no es ser la metrica final a priori. Su rol es funcionar como referencia posterior:

$$R \xrightarrow{\text{entrenar}} \mathcal{P}_R \xrightarrow{\text{medir masa}} D_{\text{stat}}(R).$$

Al repetir este procedimiento para muchos targets, aparece una pregunta nueva: si algunos targets producen sistemáticamente poblaciones pobres, entonces debe existir alguna propiedad de su forma espectral que los vuelve exigentes para el sistema. En otras palabras, D_{stat} no es todavia una explicacion; es el indicador posterior que nos dice donde buscar la explicacion.

La idea conceptual que sigue es no mirar el target punto por punto en λ , sino expresarlo como combinacion de direcciones espectrales. Esa es la entrada al modelo modal de dificultad.

Modelo modal conceptual

La pregunta que aparece despues de D_{stat} es:

¿Que estructura del target hace que la poblacion encuentre muchas, pocas o ninguna solucion cercana?

El modelo propuesto responde proyectando el target en una base espectral arbitraria

$$\mathcal{B} = \{\phi_k\}_{k \geq 0}.$$

No es necesario que esta base sea, en principio, la base final correcta. Puede ser una base matematica conveniente, una base fisica, una base aprendida desde un operador, o una base natural de dificultad todavia desconocida. Lo importante es que el target deja de verse como una lista de valores y pasa a verse como una funcion proyectada sobre direcciones espectrales.

Primero se define el residuo respecto de una referencia:

$$r(\lambda) = R(\lambda) - R_{\text{ref}}(\lambda).$$

La referencia R_{ref} no es una solucion entrenada: es solo el origen desde el cual se mide la demanda espectral del target. Si la base es ortonormal para un producto interno $\langle \cdot, \cdot \rangle$, entonces

$$\langle \phi_k, \phi_j \rangle = \delta_{kj}.$$

En el caso continuo puede tomarse, por ejemplo,

$$\langle f, g \rangle = \int_{\Lambda} f(\lambda) g(\lambda) d\lambda,$$

mientras que en el caso discretizado usado por el solver se aproxima como

$$\langle f, g \rangle \simeq \sum_{i=1}^{N_{\lambda}} w_i f(\lambda_i) g(\lambda_i).$$

Proyectar R sobre la base significa calcular, modo a modo,

$$c_k(R) = \langle R - R_{\text{ref}}, \phi_k \rangle.$$

Con esos coeficientes, el residuo se reconstruye como

$$r(\lambda) = R(\lambda) - R_{\text{ref}}(\lambda) \simeq \sum_{k=0}^{K-1} c_k(R) \phi_k(\lambda).$$

Si la base fuera completa y no hubiera truncacion, formalmente

$$r = \sum_{k \geq 0} c_k \phi_k.$$

Para K modos, la reconstruccion proyectada queda

$$R_K(\lambda) = R_{\text{ref}}(\lambda) + \sum_{k=0}^{K-1} c_k(R) \phi_k(\lambda).$$

Por tanto, el vector

$$c(R) = (c_0, c_1, c_2, \dots)$$

es la firma modal del target. Por Parseval, en una base ortonormal la energia cuadratica del residuo se reparte como

$$\|r\|^2 = \sum_k |c_k|^2.$$

Esto muestra por que los coeficientes son una descripcion natural de demanda: dicen cuanta energia espectral deposita R en cada direccion de la base. Un reflector ancho, un notch estrecho, una banda plana o una oscilacion rapida no son categorias externas: son patrones de energia distribuidos en esa firma modal.

La poblacion entrenada permite comparar esa firma pedida con la firma realmente alcanzada por los candidatos exitosos. Para cada candidato final,

$$a_{b,k} = \langle R_b - R_{\text{ref}}, \phi_k \rangle,$$

y los pesos de exito

$$w_b(R) = \frac{\exp[-e_b(R)/\sigma]}{\sum_j \exp[-e_j(R)/\sigma]}$$

definen una firma modal posterior de la poblacion exitosa:

$$\mu_k^{\text{succ}} = \sum_b w_b a_{b,k}.$$

La diferencia modal

$$\Delta c_k(R) = \mu_k^{\text{succ}}(R) - c_k(R)$$

localiza que parte de la firma del target no fue reproducida por la poblacion que si tuvo exito relativo. Asi, D_{stat} dice si el target fue dificil; la firma modal posterior empieza a decir en que direcciones espectrales aparece esa dificultad.

Este paso es conceptual: no estamos afirmando que una base particular sea la verdad final. Estamos proponiendo que toda metrica a priori debe poder leer el target como un vector de demandas modales y comparar esas demandas con la capacidad fisica inducida por C .

Punto de llegada de esta parte

Hasta aqui, el modelo construido es posterior: entrena una red para cada target R , mide la masa de la poblacion final y devuelve $D_{\text{stat}}(R)$. Luego, la proyeccion modal convierte cada target en una firma $c(R)$. El paso siguiente invierte la direccion: queremos una metrica que pueda operar sobre esa firma antes de entrenar. El primer intento fue tomar esa firma en una base simple, la DCT en $u = 1/\lambda$. El resultado no se interpreta como una base final, sino como una prueba de que la dificultad posterior deja una huella modal medible.

Resultados de los Hamiltonianos

El primer Hamiltoniano aparecio de forma implicita en la base DCT. Todavia no se lo escribia como $\hat{H}$, pero proyectar en modos DCT y penalizar modos mas oscilatorios equivale a usar, en primera aproximacion, un operador de suavidad:

$$\hat{H}_{\text{DCT}} \sim a_2(C)(-\partial_u^2).$$

Si ϕ_k es un modo DCT en $u = 1/\lambda$, entonces $-\partial_u^2 \phi_k \simeq q_k^2 \phi_k$. Por tanto,

$$D_{\text{DCT}}(R; C) \simeq \sum_k a_2(C) q_k^2 c_k^2.$$

La version numerica reemplazo ese peso ideal por pesos de accesibilidad modal α_k :

$$D_{\text{modal}}(R; C) = \sum_k \alpha_k c_k^2, \quad \alpha_k = \frac{1}{\bar{S}_k + \eta}.$$




Figure 2: Comparacion entre penalizacion modal empirica y autovalores propuestos por Hamiltonianos diagonales. La curva negra resume la penalizacion modal posterior, mientras que las curvas de color corresponden a pesos construidos desde terminos fisicos a priori. La coincidencia ordinal indica que la estructura modal contiene informacion real sobre dificultad, aunque la cola empirica crece mas bruscamente y con mas irregularidad.

Se hizo un barrido de 500 targets para corroborar esta idea. Esta familia modal tuvo senal predictiva: el mejor predictor DCT de 24 modos alcanzo aproximadamente $\rho_{\text{Spearman}} \simeq 0.81$ y $r_{\text{Pearson}} \simeq 0.67$ contra D_{stat} . El resultado mostro que la firma modal del target contiene informacion real sobre dificultad. Su falla tambien fue clara: subestima reflectores altos, anchos y planos, porque una penalizacion tipo $-\partial_u^2$ ve barato el contenido de baja frecuencia. La Fig. 2 resume precisamente esta lectura: la penalizacion empirica modal sigue un orden fisico reconocible, pero exige mas que una penalizacion DCT elemental.

Observacion. La falla de la DCT pura sugiere que una base frecuencial simple no alcanza: no basta con castigar oscilaciones. Si

$$r = R - R_{\text{ref}} = \sum_k c_k \phi_k,$$

la generalizacion natural es asignar una energia a ese vector de coeficientes. En la version diagonal,

$$D_{\text{diag}}(R; C) = \sum_k h_k(C) c_k^2,$$

cada modo se penaliza de forma independiente. Pero si las direcciones espectrales se acoplan, la energia debe permitir terminos cruzados:

$$D_H(R; C) = \sum_{k,j} H_{kj}(C) c_k c_j.$$

Si H es simetrico, esta misma forma se escribe explicitamente como

$$D_H = \sum_k H_{kk} c_k^2 + 2 \sum_{k < j} H_{kj} c_k c_j.$$

El primer termino es diagonal: mide la dificultad asociada a cada modo por separado. El segundo es no diagonal: mide acoplamientos entre pares de modos. Tambien puede descomponerse el operador en piezas fisicas,

$$\hat{H}_C = \hat{H}_1 + \hat{H}_2 + \hat{H}_3 + \dots,$$

lo que induce una suma de aportes escalares

$$D_H = \langle r, \hat{H}_1 r \rangle + \langle r, \hat{H}_2 r \rangle + \langle r, \hat{H}_3 r \rangle + \dots$$

En forma abreviada,

$$D_H = H_1(R; C) + H_2(R; C) + H_3(R; C) + \dots$$

Por ejemplo,

$$D_H = D_{\text{amp}} + D_{\text{suav}} + D_{\text{rug}} + D_{\text{na}} + \dots,$$

donde los tres primeros pueden ser diagonales y D_{na} recoge los acoplamientos fuera de la diagonal. En notacion operatorial,

$$D_H(R; C) = \langle r, \hat{H}_C r \rangle.$$

Asi aparece naturalmente el Hamiltoniano de dificultad. D_{stat} no lo define; solo mostro empiricamente que habia una dificultad que explicar. El Hamiltoniano es el intento de construir esa explicacion desde R y las condiciones fisicas C , sin esperar al entrenamiento.

A partir de esta observacion se probó un Hamiltoniano diagonal mas completo, pensado como una energia cuadratica separable:

$$\hat{H}_{\text{diag}} = a_0(C)I + a_2(C)(-\partial_u^2) + a_4(C)(\partial_u^4).$$

Los parametros a priori se eligieron de forma conveniente segun la caracteristica fisica de cada termino, sin ajustarlos contra D_{stat} . Para la fase se uso la escala de fase disponible del sistema,

$$k_{\text{phase}} = \frac{\Phi_C^{\text{max}}}{\pi}, \quad \Phi_C^{\text{max}} \sim 2\pi L n_{\text{max}} e_{\text{max}} \Delta u,$$

de modo que la penalizacion modal depende de q_k/k_{phase} , con

$$q_k = \frac{k\pi}{\Delta u}.$$

Para amplitud se uso el contraste maximo accesible,

$$\rho_C = \frac{n_{\text{max}} - n_{\text{min}}}{n_{\text{max}} + n_{\text{min}}}, \quad a_0(C) \sim \frac{1}{\rho_C^2 + \epsilon}.$$

El termino de cuarto orden se introdujo como una correcion diagonal de cola, proporcional a una potencia mayor de q_k/k_{phase} , para representar que la estructura fina debe encarecerse mas rapido que la variacion suave. En una base donde este operador es aproximadamente diagonal,

$$D_{\text{diag}}(R; C) = \sum_k h_k(C) c_k^2.$$

La interpretacion de los terminos fue la siguiente: $a_0 I$ penaliza nivel o amplitud global; $-\partial_u^2$ penaliza variacion espectral; y ∂_u^4 penaliza curvatura, rugosidad y estructura fina. El resultado importante fue doble. Por un lado, la parte modal del operador reprodujo de forma cualitativa la idea de accesibilidad: modos mas finos o menos movibles por el solver reciben pesos mayores. Por otro lado, al comparar contra D_{stat} , la parte puramente modal no alcanzo.

En el mismo barrido, el Hamiltoniano sin termino global de amplitud quedo pobre como predictor de D_{stat} . Al incorporar amplitud, nivel o contraste, la correlacion con la dificultad posterior subio de manera marcada, alcanzando una meseta robusta cercana a

$$\rho_{\text{Spearman}} \simeq 0.85.$$

La conclusion fue que la dificultad observada no vive solamente en modos altos: muchos targets dificiles, como reflectores altos, anchos y planos, son dificiles precisamente porque exigen mucha energia global en modos bajos.

Tambien se separo el limite diagonal del posible termino no abeliano:

$$\hat{H}_C = \hat{H}_{\text{diag}}(C) + \hat{H}_{\text{na}}(C).$$

La motivacion vino de la TMM. Si las matrices de capa se escriben como $M_\ell = \exp(A_\ell)$, entonces

$$\log(e^{A_2} e^{A_1}) = A_2 + A_1 + \frac{1}{2}[A_2, A_1] + \dots$$

Cuando $[A_i, A_j] = 0$, el producto se reduce a una suma de generadores y la dificultad esperada es casi separable. Cuando los conmutadores no se anulan, aparecen acoplamientos entre modos. En la descomposicion anterior, esos acoplamientos corresponden al aporte D_{na} .

Se hizo un test empirico de regimenes abelianos/no abelianos, pero no se tomo como prueba definitiva. Al forzar restricciones fuertes se redujo demasiado el conjunto alcanzable y varios targets dejaron de ser bien ajustados. Ese fracaso fue informativo: no se puede validar una metrica de dificultad restringiendo el sistema hasta que el target quede fuera de su espacio accesible. Lo que si quedo justificado fue la lectura estructural: el Hamiltoniano diagonal corresponde al limite conmutativo, y los terminos no diagonales son la forma natural de representar no conmutatividad efectiva.

Finalmente, los resultados tambien mostraron que una forma cuadratica puede no ser suficiente. Las demandas de reflectancia alta, bandas anchas, saturacion y planitud sugieren un funcional no lineal:

$$D_{\text{NL}}[r; C] = \int [V_C(r) + A_C(r)|\partial_u r|^2 + B_C(r)|\partial_u^2 r|^2 + \dots] du.$$

Asi, el camino obtenido fue: D_{stat} revela la dificultad a posteriori; la firma modal organiza lo que el target pide; H_{diag}

da el primer modelo energetico; H_{na} incorpora acoplamientos por no conmutatividad; y D_{NL} aparece como el lenguaje necesario para capturar saturaciones y demandas globales que no son puramente cuadraticas.